

UNIVERSITÉ MOULAY ISMAIL

Faculté des Sciences de Meknès

Département d'Informatique

Parcours d'Excellence - Master SDIA 2025–2026

Rapport d'État d'Avancement Sprint 4

Agentic GraphRAG pour le Raisonnement Complexe sur des Corpus Techniques

SPRINT 4 - Ablation Study comparative
(RAG baseline vs LightRAG hy-
bride vs Agentic GraphRAG)

et stabilisation du protocole d'évaluation

29 Juin – 30 Juillet 2026

Étudiante : Wiame Anejjar

Encadrant : Pr. Abdelaaziz Hessane

Parcours : Master SDIA 2025–2026

Université : Moulay Ismail — FSM

Date : 30 Juillet 2026

Table des matières

Résumé Exécutif	5
0.1 Post-traitement du graphe de connaissances LightRAG	8
0.1.1 Problème observé	8
0.1.2 Solution appliquée	8
0.1.3 Résultats quantitatifs	8
0.2 Construction et validation du benchmark multi-hop final	9
0.2.1 Rappel : incompatibilité de HotpotQA avec le corpus	9
0.2.2 Critères de validation automatique	9
0.2.3 Résultat	9
0.3 Correction d'un bug critique du pipeline de retrieval	10
0.4 Protocole de l'Ablation Study	10
0.4.1 Objectif	10
0.4.2 Configuration expérimentale	11
0.5 Échecs successifs du juge RAGAS automatique	11
0.5.1 Tentative 1 : Google Gemini	12
0.5.2 Tentative 2 : DeepSeek via NVIDIA	12
0.5.3 Tentative 3 : Gemini reconfiguré selon le plan de l'encadrant	12
0.5.4 Tentatives 4 et 5 : OpenRouter	13
0.5.5 Décision finale	13
0.6 Basculement vers l'évaluation manuelle : Plan C	13
0.6.1 Grille de notation	14
0.6.2 Protocole	14
0.7 Premiers résultats de l'Ablation Study : un résultat contre-intuitif	14
0.8 Diagnostic de la sous-performance de l'Agentic GraphRAG	14
0.8.1 Analyse question par question	15
0.9 Corrections appliquées à l'agent	15
0.9.1 Architecture corrigée de l'agent	17
0.9.2 Historique des itérations de correction	17
0.10 Résultats finaux et interprétation	18
0.11 Limites identifiées	19

0.12 Synthèse comparative 19

0.13 Perspectives - Sprint 5 19

Table des figures

1	Architecture de l'agent après correctifs (<code>src/agent/graph_v3.py</code>) . . .	17
---	---	----

Liste des tableaux

1	Impact du post-traitement du graphe	8
2	Critères de validation des questions multi-hop	9
3	Configuration des 3 systèmes comparés	11
4	Critères de la grille de notation manuelle (Plan C)	14
5	Résultats de la première exécution de l’ablation study (25/07/2026, Plan C, 10 questions)	15
6	Correctifs appliqués à l’agent (26–30/07/2026)	16
7	Résultats de l’ablation study après correctifs combinés (30/07/2026) . .	18
8	Évolution du score de l’Agentic GraphRAG au fil des correctifs	18

Résumé Exécutif

Sprint 4 — Vue d'ensemble

Période : 29 Juin – 30 Juillet 2026

Thème : Ablation study comparative (RAG baseline ChromaDB vs LightRAG hybride vs Agentic GraphRAG) sur un même benchmark et une même configuration expérimentale, diagnostic et correction de la sous-performance initiale de l'Agentic GraphRAG

Statut : **Terminé** : résultats exploitables obtenus par évaluation manuelle après échec de cinq juges RAGAS automatiques successifs

Ce qui était prévu

Conformément aux perspectives définies à la fin du Sprint 3, les objectifs du Sprint 4 étaient :

- Post-traiter le graphe de connaissances LightRAG afin de réduire la fragmentation observée (composantes isolées, faible densité).
- Construire un benchmark définitivement validé de questions réellement multi-hop.
- Corriger le protocole d'évaluation RAGAS (juge indépendant du générateur, correction du passage du contexte).
- Intégrer LightRAG directement comme moteur de retrieval de l'agent (remplacement des requêtes Cypher manuelles).
- Construire un notebook d'ablation study comparant, dans des conditions strictement identiques (même corpus, même benchmark, même générateur), trois architectures : RAG vectoriel seul, LightRAG hybride seul, et Agentic GraphRAG complet.
- Produire une synthèse comparative chiffrée exploitable pour le mémoire final.

Ce qui a été fait

- Post-traitement du graphe : fusion de 103 groupes d'entités dupliquées, ajout de relations de co-occurrence, augmentation des relations de 5068 à 5593, suppression complète des nœuds isolés, composante géante portée de 43,3 % à 55,3 %.
- Validation automatique du benchmark multi-hop selon 4 critères objectifs (présence de l'entité de départ, absence de fuite de la réponse, non-redondance des sauts, chunks sources distincts) : obtention de 76 vraies questions multi-hop sur 100 générées.
- Identification et correction d'un bug critique du pipeline de retrieval (`AttributeError: 'list' object has no attribute 'size'`) intercepté silencieusement dans `node_hybrid_search`, qui annulait la récupération de contexte sans jamais faire échouer l'agent.
- Réalisation d'une nouvelle version de l'agent (`src/agent/graph_v3.py`) fondée directement sur le retrieval hybride natif de LightRAG.
- Construction du notebook `Sprint4_Ablation_Study.ipynb` comparant les 3 architectures sur le même jeu de questions et les mêmes métriques.
- Échec successif de **cinq** tentatives de juge RAGAS automatique (Google Gemini, DeepSeek/NVIDIA, deux modèles OpenRouter) pour des causes différentes à chaque fois (quota à 0, limite de concurrence, modèle retiré de l'offre gratuite).
- Basculement définitif vers une évaluation manuelle structurée (*Plan C*, proposée par l'encadrant) sur 3 critères booléens (correct / ancré au contexte / clair et complet).
- Première mesure de l'ablation study (25/07) : résultat contre-intuitif où LightRAG hybride seul (0,57) surpasse l'Agentic GraphRAG (0,43), pourtant nettement plus coûteux en latence (25,4 s contre 12,5 s).
- Diagnostic question par question révélant que l'agent refusait de répondre (*"The corpus does not contain information..."*) sur 5 des 10 questions alors que l'information était explicitement présente dans le contexte récupéré.
- Application de cinq correctifs ciblés sur l'agent (prompt de réponse nuancé, réordonnancement et élargissement du contexte, alignement du contexte du juge CRITIQUE sur celui du générateur, suivi de la meilleure réponse sur toutes les itérations, vérification obligatoire des refus par le juge CRITIQUE).
- Nouvelle campagne de notation manuelle après combinaison de tous les correctifs : l'Agentic GraphRAG passe de 0,43 à **0,50**, rejoignant LightRAG hybride (0,50) et se détachant nettement du RAG baseline (0,33).

Ce qui reste à faire

- Étendre l'évaluation manuelle Plan C de l'échantillon actuel (10 questions) aux 76 questions validées du benchmark final, pour consolider statistiquement le résultat.
- Documenter le résultat de l'ablation study (avant/après correctifs) dans le mémoire final, en assumant la méthodologie de diagnostic plutôt que de la masquer.
- Reprendre la rédaction du mémoire final (chapitres État de l'art et Méthodologie), échéance fixée au ; 30 août 2026.

0.1 Post-traitement du graphe de connaissances LightRAG

0.1.1 Problème observé

Problème

Malgré les améliorations successives du pipeline d'extraction depuis le Sprint 2 (normalisation des entités, filtrage des relations génériques), le graphe de connaissances construit sur les 500 documents restait fortement fragmenté : de nombreuses composantes connexes isolées, un degré moyen faible, et une composante géante ne couvrant qu'une minorité des nœuds.

0.1.2 Solution appliquée

Solution

Un script de post-traitement **sans réindexation du corpus**, `merge_entity_aliases.py`, a été exécuté directement sur le graphe exporté :

- Fusion des groupes d'entités identifiées comme des alias de la même entité (variantes de casse, sigles, formulations proches).
- Ajout automatique de relations de co-occurrence entre entités apparaissant fréquemment dans les mêmes passages, lorsque cela réduisait la fragmentation sans introduire de bruit sémantique.

0.1.3 Résultats quantitatifs

Métrique	Avant	Après
Groupes d'entités dupliquées fusionnées	—	103
Nombre de relations	5068	5593
Nœuds isolés	présents	0
Composante géante	43,3 %	55,3 %
Composantes connexes	534	385

TABLE 1 – Impact du post-traitement du graphe

0.2 Construction et validation du benchmark multi-hop final

0.2.1 Rappel : incompatibilité de HotpotQA avec le corpus

Comme identifié dès le Sprint 2, le benchmark standard HotpotQA repose sur Wikipédia et n’a quasiment aucun recouvrement thématique avec le corpus arXiv CS.AI du projet. Vérification empirique : sur les 7405 questions HotpotQA, seules 2 contiennent une entité existant littéralement dans le graphe LightRAG, et il s’agit de coïncidences lexicales sans rapport thématique réel (ex. jeux de société *Power Grid/Splendor*). HotpotQA a donc été définitivement écarté au profit d’un benchmark synthétique généré à partir du graphe lui-même.

0.2.2 Critères de validation automatique

Un script dédié, `validate_multihop_benchmark.py`, a été développé pour distinguer automatiquement les vraies questions multi-hop des questions pseudo multi-hop, indépendamment de leur étiquette d’origine (`hop_type`).

Critère	Description	Si non respecté
Présence de l’entité de départ	La question fait explicitement référence à <code>entity_A</code> ou à un équivalent	SINGLE_HOP
Absence de fuite de la réponse	Le <code>ground_truth</code> n’apparaît pas déjà dans l’énoncé	SINGLE_HOP
Non-redondance des sauts	Similarité de Jaccard entre <code>hop1</code> et <code>hop2</code> suffisamment faible	SINGLE_HOP
Chunks sources distincts	Les deux relations proviennent de chunks (idéalement documents) différents	PSEUDO_MULTI_HOP

TABLE 2 – Critères de validation des questions multi-hop

0.2.3 Résultat

Résultat

Sur 100 questions générées, le filtrage automatique a conservé **76 vraies questions multi-hop** (TRUE_MULTI_HOP), constituant le benchmark de référence utilisé pour la suite du sprint. L’échantillon effectivement noté manuellement lors de l’ablation study (10 questions, section 0.6) en est un sous-ensemble.

0.3 Correction d'un bug critique du pipeline de retrieval

Problème

Lors de l'analyse du fichier `graph_v3.py`, une exception à l'exécution a été identifiée :

```
AttributeError: 'list' object has no attribute 'size'
```

Cette exception était interceptée silencieusement (bloc `try/except` sans relèvement) à l'intérieur de `node_hybrid_search`, ce qui permettait à l'agent de continuer son exécution normalement tout en retournant un contexte vide sans jamais signaler l'erreur.

Cause identifiée : La fonction d'embedding retournait une liste Python de vecteurs au lieu d'un tableau NumPy 2D, format pourtant attendu par LightRAG (problème déjà rencontré et corrigé au Sprint 1 sur un autre point du pipeline, réapparu ici sur un chemin de code différent).

Solution

Listing 1 – Correctif appliqué à la fonction d'embedding

```
1 # Avant : la fonction retournait une liste Python
2 return embeddings
3
4 # Apres : conversion explicite en tableau NumPy 2D
5 return np.vstack(embeddings) # shape (n_textes, 768)
```

Résultat

Ce diagnostic a permis de confirmer que le problème ne provenait **ni** de la qualité du graphe post-traité, **ni** du mécanisme de critique, mais d'un bug ponctuel dans la couche d'embedding une distinction importante pour ne pas engager de travail correctif inutile sur le mauvais composant.

0.4 Protocole de l'Ablation Study

0.4.1 Objectif

L'ablation study vise à isoler la contribution propre de chaque couche du système en comparant, sur le **même benchmark**, le **même corpus indexé** et

le **même modèle générateur**, trois architectures de complexité croissante :

1. **RAG baseline (ChromaDB)** : retrieval vectoriel simple, sans graphe, sans boucle agentique.
2. **LightRAG hybride (sans agent)** : retrieval graphe + vecteurs natif de LightRAG, un seul appel de génération, sans mécanisme de critique.
3. **Agentic GraphRAG** : même retrieval que (2), encapsulé dans la boucle complète `QUERY → RESPONSE → CRITIQUE → SELF_CORRECT/FINALIZE`.

0.4.2 Configuration expérimentale

	RAG baseline	LightRAG hybride	hy-	Agentic phRAG	Gra-
Backend	ChromaDB	LightRAG	(post-	LightRAG	(iden-
Corpus indexé	1587 chunks (nomic-embed- text, chunk=900, overlap=120)	4945 nœuds / relations	5593	identique	
Paramètres retrieval	top_k=5	mode=hybrid, top_k=15, chunk_top_k=10		identique	
Générateur	Groq llama-3.1-8b -instant	Groq llama-3.1-8b -instant		Groq llama-3.1-8b-instant	
Boucle agentique	non	non (1 appel)		oui , juge Groq llama-3.3-70b-versatile (indépendant), seuil critique = 0,75, max 3 itérations	

TABLE 3 – Configuration des 3 systèmes comparés

L'indépendance entre le modèle générateur (`llama-3.1-8b-instant`) et le modèle juge (`llama-3.3-70b-versatile`) a été imposée au niveau du code afin d'éviter tout biais d'auto-évaluation.

0.5 Échecs successifs du juge RAGAS automatique

Contrairement aux sprints précédents où RAGAS échouait pour des raisons de configuration (contexte monolithique, absence de juge indépendant), le Sprint 4 a fait face à une série d'échecs **indépendants du code de l'agent**, liés exclusivement à la disponibilité des API de juges LLM externes. Cinq tentatives successives ont été menées.

0.5.1 Tentative 1 : Google Gemini

Problème

Première exécution complète de l'ablation study avec Gemini (gemini-2.0-flash) comme juge RAGAS. Résultat : **100 % de NaN** sur les 4 métriques (faithfulness, answer_relevancy, context_precision, context_recall) pour les 3 systèmes.

```
429 RESOURCE_EXHAUSTED - quota limit: 0 (tier gratuit)
```

Diagnostic : chaque appel épuise les 5 tentatives de retry sans jamais obtenir de réponse, quota strictement nul sur le compte utilisé.

0.5.2 Tentative 2 : DeepSeek via NVIDIA

Problème

Remplacement du juge par deepseek-ai/deepseek-v4-pro via l'API NVIDIA (déjà présente comme option de repli dans eval_ragas_3.py). Test de validation isolé concluant (réponse JSON propre en 8,2s). Première exécution complète : nette amélioration (60–70 % de NaN au lieu de 100 %), mais toujours inexploitable.

Diagnostic : 429 Too Many Requests réel, causé par max_workers=2 qui fait tourner des requêtes en parallèle malgré batch_size=1.

Solution

Correctif (max_workers=1 dédié au juge NVIDIA) appliqué, mais non revallidé avant la tentative suivante.

0.5.3 Tentative 3 : Gemini reconfiguré selon le plan de l'encadrant

Problème

Suite au retour de l'encadrant du 25/07 (Plan A/B/C), relance de Gemini avec convert_system_message_to_human=True, batch_size=2, seuil de NaN abaissé à 10 %. Échec **identique** à la tentative 1 : 429 RESOURCE_EXHAUSTED, limit: 0 sur toutes les métriques de quota (tokens, requêtes/minute, requêtes/jour), dès la première requête.

Conclusion : blocage total au niveau du compte/projet Google associé à la

clé, indépendant du code ou de la concurrence. Le Plan B de repli (5 questions, `max_workers=1`) est écarté sans être testé, car un `limit: 0` bloque une requête unique aussi bien que quarante.

0.5.4 Tentatives 4 et 5 : OpenRouter

Problème

Ajout d'un juge supplémentaire via OpenRouter, `google/gemma-3-27b-it:free`. Échec systématique (100 % de NaN) :

```
404 - "This model is unavailable for free...
      use this slug instead: google/gemma-3-27b-it"
```

Remplacement par le modèle de repli `meta-llama/llama-3.3-70b-instruct:free` : **même erreur 404**, même cause. Les deux modèles ont été retirés de l'offre gratuite d'OpenRouter malgré le suffixe `:free` encore affiché.

0.5.5 Décision finale

Décision

Après cinq échecs consécutifs sur quatre fournisseurs différents (Groq initialement, Gemini, DeepSeek/NVIDIA, OpenRouter $\times 2$), chacun pour une cause distincte (quota nul, limite de concurrence, modèle retiré), la décision a été prise d'**abandonner définitivement la mesure automatique RAGAS** pour cette échéance, et de basculer sur l'évaluation manuelle déjà prévue en repli (*Plan C*, section 0.6).

Il est important de souligner que ces échecs sont extérieurs au système développé : le protocole d'ablation study lui-même (isolation retrieval/boucle agentique, mêmes questions, même générateur) était validé et fonctionnel dès le 24/07 ; seule la brique de scoring automatique externe s'est avérée non fiable sur les offres gratuites disponibles.

0.6 Basculement vers l'évaluation manuelle : Plan C

0.6.1 Grille de notation

Sur proposition de l'encadrant, un protocole d'évaluation manuelle simple et reproductible a été mis en place, sur 3 critères binaires (0 ou 1) par réponse :

Critère	Description
<code>correct</code>	La réponse correspond factuellement au <code>ground_truth</code> attendu.
<code>ancré_contexte</code>	La réponse ne contient pas d'information absente du contexte récupéré (pas d'hallucination).
<code>clair_complet</code>	La réponse est claire, structurée et complète par rapport à la question posée.

TABLE 4 – Critères de la grille de notation manuelle (Plan C)

Le score moyen d'un système est la moyenne des 3 critères, moyennée sur l'ensemble des questions notées.

0.6.2 Protocole

Pour chaque question de l'échantillon retenu (10 questions), les 3 systèmes génèrent chacun une réponse dans les mêmes conditions (même prompt utilisateur, même corpus). Les 30 triplets (question, réponse, contexte) sont exportés dans `Eval_agentic/plan_c_evaluation_manuelle.csv`, notés manuellement selon la grille ci-dessus, puis agrégés par système dans `Eval_agentic/plan_c_resultats_agreges.csv`.

Résultat

Un repli automatique a été ajouté dans le notebook : la cellule "Tableau comparatif" bascule désormais sur les résultats du Plan C si les DataFrames RAGAS (Gemini/DeepSeek/OpenRouter) sont absents, au lieu de lever une exception (`NameError`).

0.7 Premiers résultats de l'Ablation Study : un résultat contre-intuitif

0.8 Diagnostic de la sous-performance de l'Agentic GraphRAG

Système	Correct	Ancré	Clair/complet	Score moyen	Latence
RAG baseline (ChromaDB)	0,10	1,00	0,00	0,37	6,7 s
LightRAG hybride	0,40	0,80	0,50	0,57	12,5 s
Agentic GraphRAG	0,30	0,70	0,30	0,43	25,4 s

TABLE 5 – Résultats de la première exécution de l’ablation study (25/07/2026, Plan C, 10 questions)

0.8.1 Analyse question par question

Problème

La lecture détaillée de `Eval_agentic/eval_agent_s4.csv` et de `plan_c_evaluation_manuelle.csv` a montré que, sur 5 des 10 questions (dont *PyPOTS*, *QED*, *MindTrellis/Quantum Knowledge Graph*), l’agent répondait *"The corpus does not contain information to answer this question"* **alors que l’information était explicitement présente** dans le contexte récupéré, parfois citée juste après dans la même réponse.

Exemple : question QED : le contexte récupéré contient littéralement *"QED, an open-source multi-agent proof system"*. L’agent refuse pourtant de répondre, invoquant l’absence d’information dans le corpus.

Cinq causes racines distinctes, s’additionnant, ont été identifiées (elles sont détaillées dans le journal).

0.9 Corrections appliquées à l’agent

Cinq correctifs ciblés ont été appliqués dans `src/agent/graph_v3.py`, chacun répondant à une des causes identifiées ci-dessus.

Correctif 1 : Nouvelle règle du prompt RESPONSE

```

1 2. If the context contains partial information ,
   provide what
2   you can and mark the gaps with [not in corpus].
3 3. Only reply "The corpus does not contain
   information..."
4   if NONE of the retrieved documents mentions the
   subject
5   of the question at all.
6 4. When a document explicitly mentions an entity from
   the

```


#	Correctif	Cause traitée
1	Prompt RESPONSE nuancé (<i>Option A</i>) : extraction des faits partiels avant refus, refus réservé au cas où <i>aucun</i> document ne mentionne le sujet	Cause 1
2	Réordonnancement du contexte (passages → relations → entités) et augmentation de la limite à 8000 caractères	Cause 2
3	Alignement du contexte du juge CRITIQUE sur MAX_GENERATOR_CONTEXT_CHARS (800 → 8000)	Cause 3
4	Suivi de <code>best_response/best_score</code> sur toutes les itérations ; <code>FINALIZE</code> renvoie la meilleure, pas la dernière	Cause 4
5	Vérification obligatoire par le juge : avant de noter un refus $\geq 0,8$, re-vérifier ex- plicitement si le sujet apparaît dans le contexte ; noter $< 0,4$ si c'est le cas	Cause 5

TABLE 6 – Correctifs appliqués à l'agent (26–30/07/2026)

```

7 question, extract the relevant facts BEFORE deciding
8 to refuse.

```

Correctif 4 : Suivi de la meilleure réponse dans FINALIZE

Listing 2 – Principe du suivi de `best_response`

```

1 if current_score > state["best_score"]:
2     state["best_response"] = state["response"]
3     state["best_score"] = current_score
4     state["best_retrieved_contexts"] =
5         state["contexts"]
6 # FINALIZE retourne désormais best_response, pas
7 response

```

0.9.1 Architecture corrigée de l'agent




FIGURE 1 – Architecture de l'agent après correctifs (src/agent/graph_v3.py)

0.9.2 Historique des itérations de correction

À noter

Il est important de noter que les correctifs 1 et 3 avaient déjà été tentés isolément le 25/07 (élargissement du retrieval au **SELF_CORRECT**, alignement du contexte du juge), **sans amélioration mesurable** (score inchangé à 0,43, une régression détectée), ce qui avait conduit à une restauration temporaire du code. Ce n'est qu'en **combinant** les 5 correctifs, en particulier le réordonnancement du contexte (correctif 2) et la vérification des refus par le juge (correctif 5), jamais testés conjointement auparavant, que l'amélioration s'est concrétisée (section suivante).

0.10 Résultats finaux et interprétation

Après application combinée des 5 correctifs, une nouvelle campagne de notation manuelle (Plan C) a été exécutée le 30/07/2026 sur le même échantillon de 10 questions.

Système	Correct	Ancré	Clair/complet	Score moyen
RAG baseline (ChromaDB)	0,00	1,00	0,00	0,33
LightRAG hybride (sans agent)	0,20	1,00	0,30	0,50
Agentic GraphRAG	0,20	1,00	0,30	0,50

TABLE 7 – Résultats de l’ablation study après correctifs combinés (30/07/2026)

Étape	Score moyen
Résultat initial (25/07, avant correctifs)	0,43
Après correctifs 1+3 isolés (25/07, abandonnés ,pas d’amélioration)	0,43
Après correctifs 1+2 combinés (26–30/07, intermédiaire)	0,40
Après les 5 correctifs combinés (30/07, final)	0,50

TABLE 8 – Évolution du score de l’Agentic GraphRAG au fil des correctifs

Interprétation

Le résultat final montre une **parité exacte** entre LightRAG hybride et l’Agentic GraphRAG sur les 3 critères pris individuellement (0,20/1,00/0,30 pour les deux systèmes). Ceci s’explique naturellement par le fait que les deux systèmes partagent désormais le même retrieval et, une fois le biais de refus corrigé, convergent vers la même qualité de réponse de base.

- L’Agentic GraphRAG a **comblé un écart de 0,14 point** (0,43 → 0,50, soit +16 % relatif) en éliminant la cause structurelle de sa sous-performance : des refus injustifiés que ni le prompt, ni le juge de qualité interne ne parvenaient auparavant à intercepter.
- Les deux systèmes basés sur LightRAG restent nettement au-dessus du RAG baseline vectoriel (0,50 contre 0,33, soit +52 %), confirmant l’apport du retrieval hybride graphe+vecteurs par rapport à une recherche vectorielle simple, indépendamment de la couche agentique.

0.11 Limites identifiées

Limites de l'ablation study actuelle

- **Taille de l'échantillon.** Les résultats chiffrés reposent sur seulement 10 questions notées manuellement, sur les 76 vraies questions multi-hop disponibles dans le benchmark validé. Une conclusion statistiquement robuste nécessiterait d'étendre la notation à l'ensemble du benchmark.
- **Absence de corroboration RAGAS.** Faute de juge automatique disponible et stable (section 0.5), aucune mesure quantitative indépendante ne vient corroborer l'évaluation manuelle, qui reste par nature partiellement subjective malgré une grille de critères explicite.
- **Résultat non généralisé au corpus complet.** Le benchmark reste construit à partir d'un corpus de 500 abstracts arXiv ; l'avantage potentiel de la boucle agentique pourrait être plus visible sur un corpus plus large.

0.12 Synthèse comparative

Ce qu'il faut retenir

L'ablation study a mis en évidence, puis corrigé, un biais méthodologique central : un prompt trop conservateur combiné à un juge de qualité interne incapable de vérifier ses propres refus produisait des réponses *"The corpus does not contain information..."* même lorsque l'information était présente dans le contexte. Une fois cette cause isolée et corrigée (5 correctifs combinés), l'Agentic GraphRAG rejoint LightRAG hybride en score moyen (0,50 chacun), et les deux systèmes basés sur LightRAG dépassent nettement le RAG baseline vectoriel (0,33). Ce parcours de diagnostic de la découverte d'un résultat contre-intuitif à sa correction méthodique constitue en soi un résultat scientifique documentable dans le mémoire final, indépendamment du score absolu obtenu.

0.13 Perspectives - Sprint 5

1. **Rédaction du mémoire final**, (échéance : 30 août 2026) en réutilisant les rapports de Sprints 1 à 4 comme matière première.
2. **Documentation du résultat de l'ablation study** dans le chapitre Résultats/Discussion du mémoire, en présentant à la fois le résultat initial

contre-intuitif et le processus de diagnostic/correction , une démarche jugée plus mature qu'un résultat "trop parfait" dès la première mesure.

Rapport rédigé le 30 juillet 2026

Wiame ANEJJAR - Master SDIA, Faculté des Sciences de Meknès